دانشگاه تهران
دانشکده مهندسی برق و کامپیوتر

گزارش پروژه پایانی درس آمار و احتمال مهندسی

دانشور امراللهی
شماره دانشجویی: ۸۱۰۱۹۷۶۸۵

سوال اول (تمیز کردن داده‌ها)

راه های متفاوتی برای برخورد با داده‌هایی که مقادیر نامعلوم دارند وجود دارند که از ساده‌ترین آن‌ها می‌توان به موارد زیر اشاره کرد:
۱- در نظر نگرفتن آن داده‌ها
۲- درنظر گرفتن مقداری پیش‌فرض برای آن
۳- در نظر گرفتن مقدار میانگین بقیه داده‌ها به جای متغیر با مقدار نامعلوم
۴- در نظر گرفتن یکی از مقادیر معلوم به صورت رندوم با توزیع یکنواخت به جای متغیر با مقدار نامعلوم
روش‌های پیشرفته تری از جمله kNN-imputation یا minimal value adjustment نیز وجود دارند

در دیتاست داده شده، مقادیر نامعلوم با ؟ مشخص شده‌اند. با استفاده از کتابخانه dplyr ابتدا با استفاده از تابع mutate مقادیر ؟ را با NA جایگزین میکنیم

داده‌های عددی که مقدار آن‌ها NA است را با mean بقیه داده‌ها جایگزین میکنیم
برای داده‌های غیر عددی نیز مقدار آن‌ها را با مد جایگزین میکنیم

سوال دوم

متغیر عددی age انتخاب شد. برای مشاهده نمودارهای مطلوب به شکل ۱،۲ و ۳ مراجعه کنید

سوال چهارم

به شکل ۴ مراجعه کنید

سوال پنجم

بازه اطمینان به شکل زیر به‌دست می‌آید

$$\bar{X} \pm Z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$$

که در این مثال داریم:

$$\bar{X} = 38.64,\ Z_{1-\frac{\alpha}{2}} = 1.96,\ \sigma = 13.71,\ n = 100$$

بازه اطمینان برابر (۴۱.۳۲و ۳۵.۹۵) می شود که به ازای ده بار اجرا کردن کد، هر ده دفعه میانگین نمونه در بازه بالا قرار گرفت که با توجه به احتمال ٪۹۵ درصدی هر دفعه، نتیجه قابل پیش‌بینی بود

آزمون فرض:
فرض کنید میانگین نمونه‌ای برابر ۳۶.۱۲ شده است

$$P(\bar{X} \leq 36.12 \mid \mu = 38.64) = P(Z \leq \frac{36.12 - 38.64}{\frac{13.71}{10}}) = P(Z \leq -1.83) = 0.15 > 0.05$$

از روی نمودار Q-Q در شکل ۵ مشاهده می‌شود متغیر سن تقریبا دارای توزیع نرمال است

سوال ششم

نمودار scatter را برای متغیرهای fnlwgt و age در شکل ۶ رسم کرده ایم. همچنین نمودار Q-Q را در شکل ۷ نشان داده‌ایم.
ضریب همبستگی پیرسون برابر ۰.۰۷۶- است
ضریب همبستگی اسپرمن برابر ۰.۰۷۷- است
همانطور که از روی نمودار scatter مشهود است به وضوح این دو متغیر correlated نیستند و انتظار عددی با قدر مطلق نزدیک به صفر داشتیم که همین به دست آمد نمودار Q-Q نشان می‌دهد آیا دو متغیر هم توریع هستند یا خیر

سوال هفتم

طبق قضیه حدمرکزی هرچه تعداد نمونه‌های ۵۰ تایی بیش‌تر می‌شود، هیستوگرام‌های رسم شده به منحنی نرمال شبیه‌تر می‌شود که از روی شکل‌های ۹ تا ۱۳ مشهود است.

سوال هشتم

در دیتاست فقط ۴ ستون age، fnlwgt، educational.num، hours.per.week دارای مقادیر عددی مناسب برای بررسی هستند. همبسنگی هر ۶ جفت ممکن از این‌ها بررسی شد و هیچکدام ضریب همسبتگی بیشتر از ۰.۳ نداشتند که بتوان برای آن‌ها خط رگرسیون معقولی محاسبه کرد

به تحصیلات از مقدار کم به زیاد عدد از ۰ تا ۷۵۰ نسبت داده‌شد. شکل ۱۴ نشان می‌دهد با افزایش تحصیلات، افزایش درآمد داریم.
اگر به جای درآمد بیشتر از ۵۰هزار دلار مقدار یک و به جای درآمد کمتر از ۵۰هزار دلار مقدار ۰ در نظر بگیریم و ضریب هم بستگی این دو مقدار را حساب کنیم، مقدار ۰.۲۶ به دست می‌آید که نشان می‌دهد این دو متغیر وابسته هستند

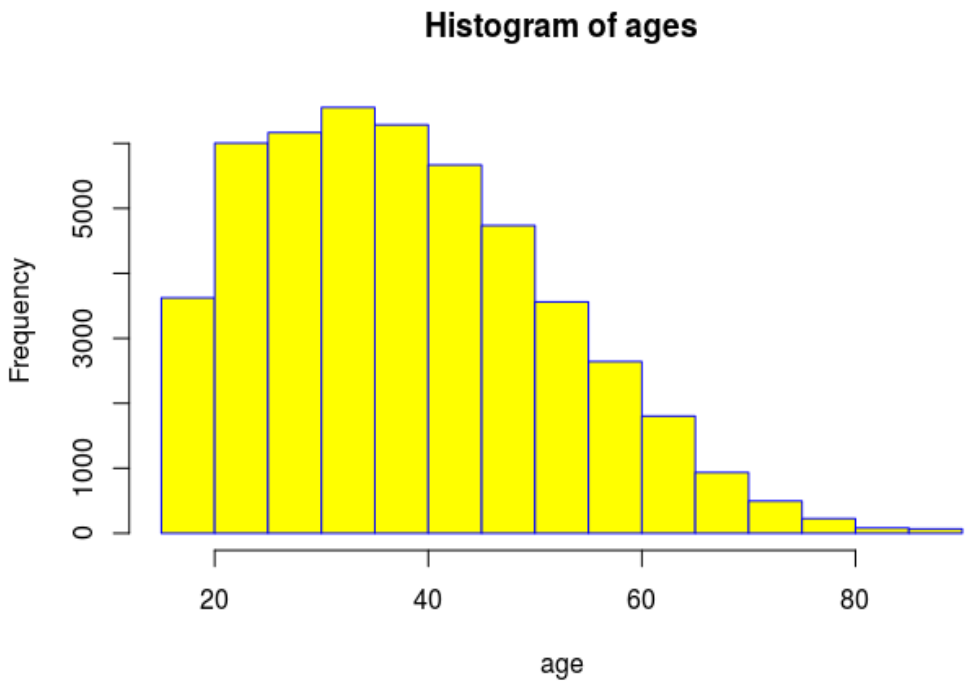

شکل ۱: نمودار هیستوگرام متغیر ages

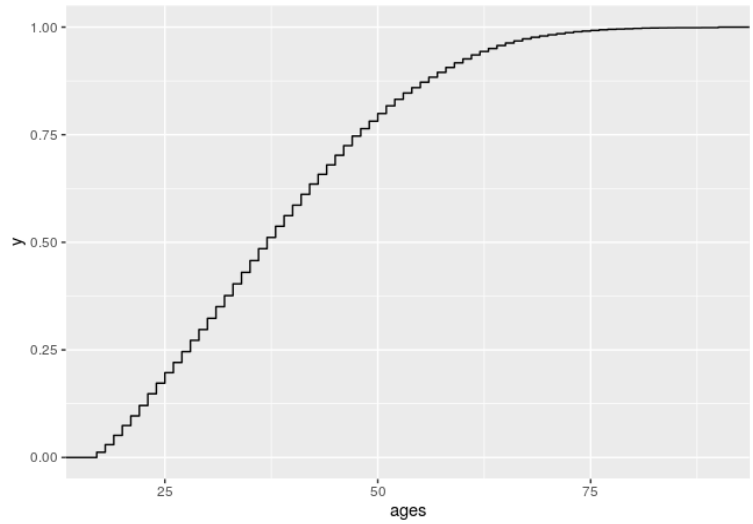

شکل ۲: نمودار توزیع تجمعی متغیر ages

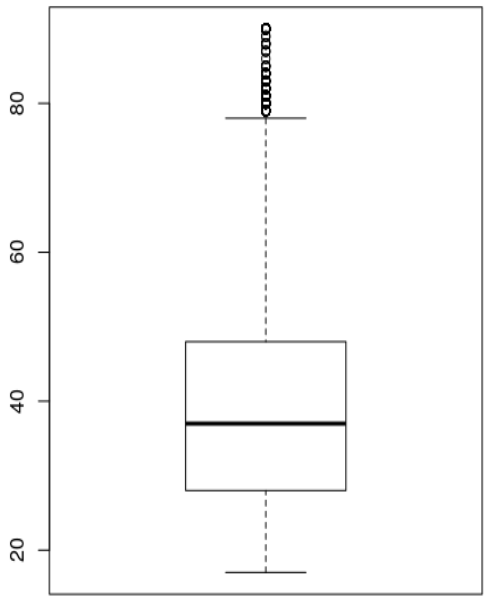

شکل ۳: نمودار جعبه‌ای متغیر ages

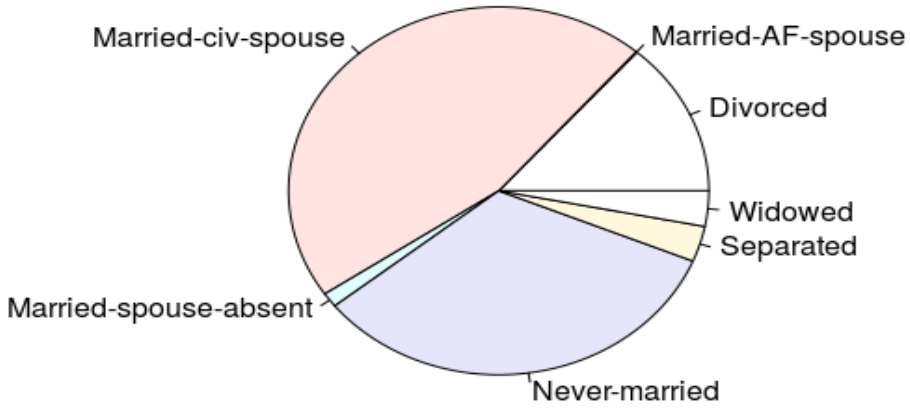

شکل ۴: نمودار دایره‌ای وضعیت تاهل

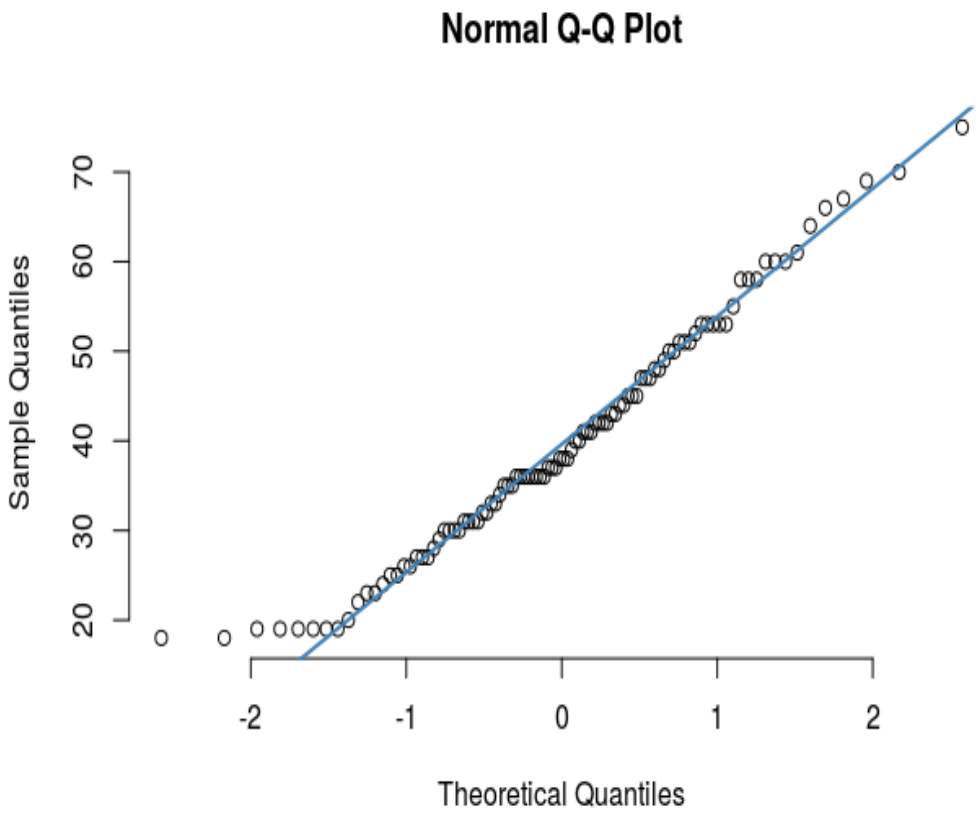

شکل ۵: نمودار Q–Q برای نمونه‌ای ۱۰۰ تایی از ages

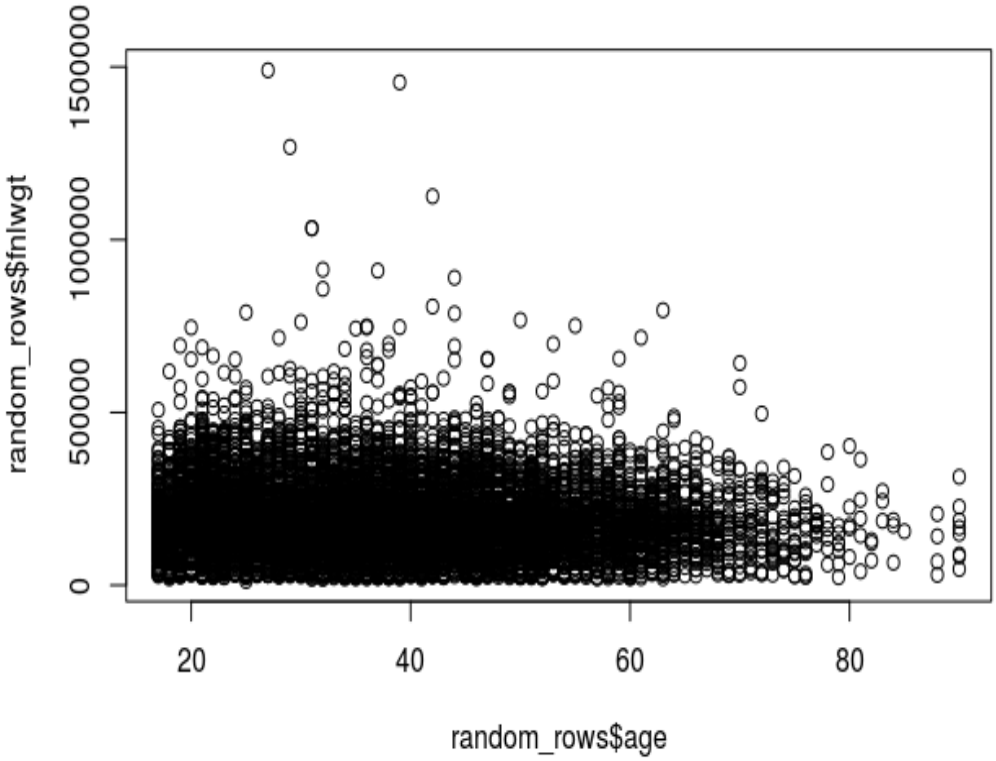

شکل ۶: نمودار پراکندگی بین متغیرهای fnlwgt و age

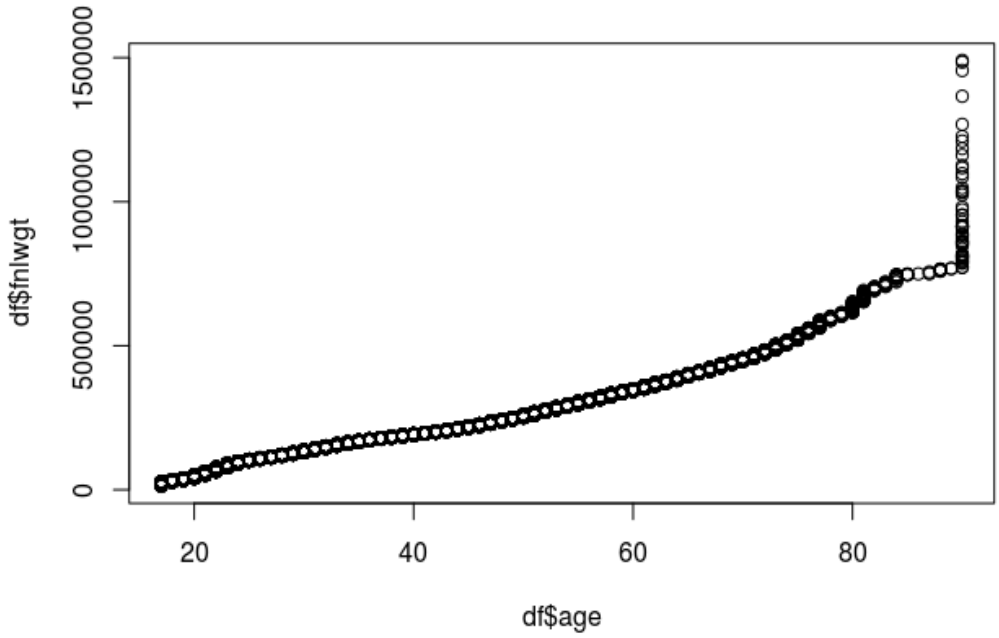

شکل ۷: نمودار qq متغیرهای fnlwgt و age

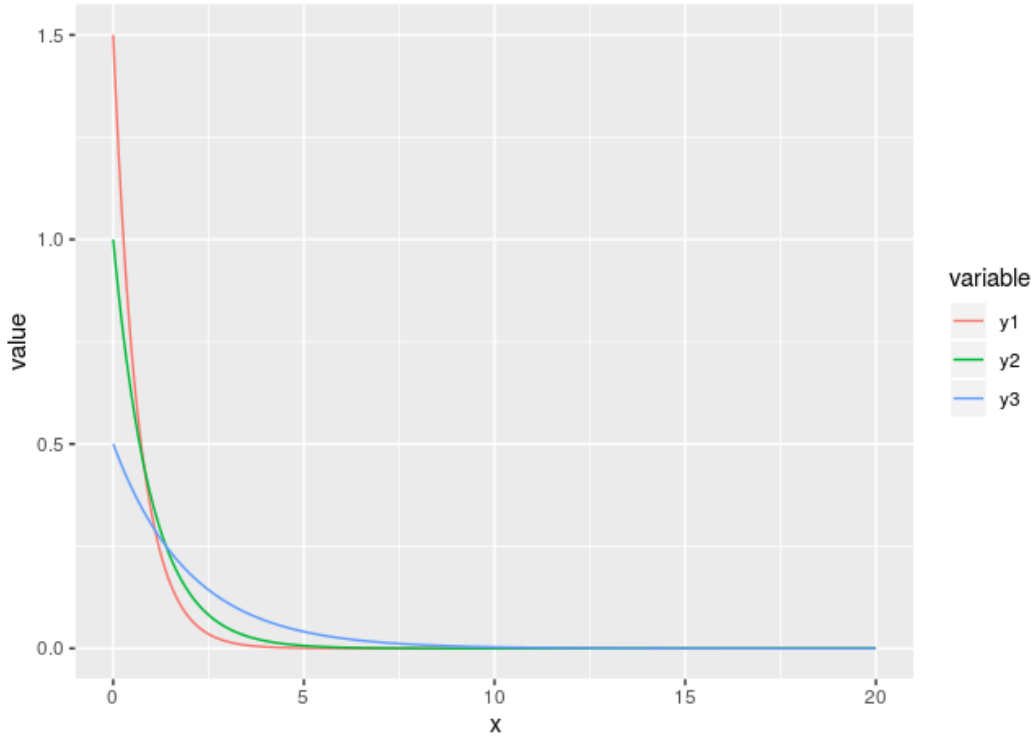

شکل ۸: نمودار نمایی به ازای پارامترهای مختلف

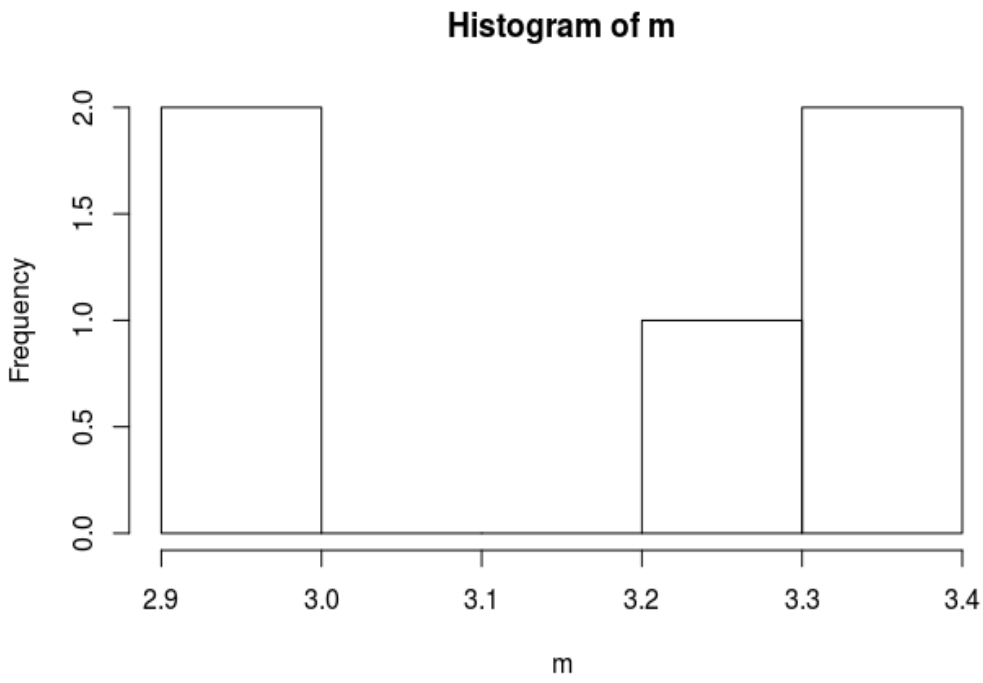

شکل ۹: هیستوگرام ۵ نمونه به سایز ۵۰ از توزیع نمایی

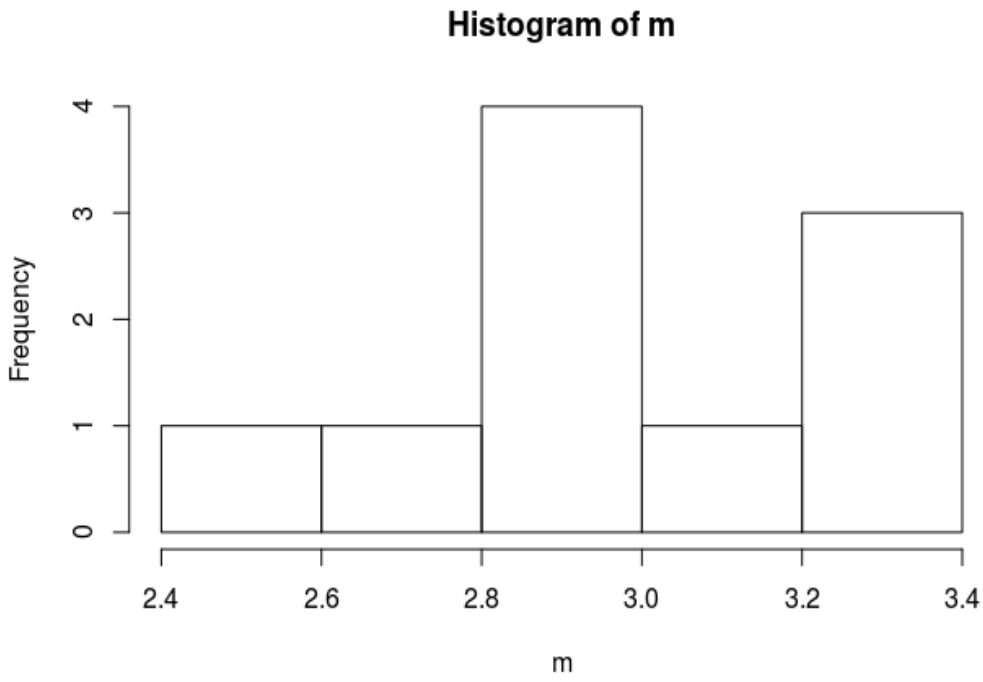

شکل ۱۰: هیستوگرام ۱۰ نمونه به سایز ۵۰ از توزیع نمایی

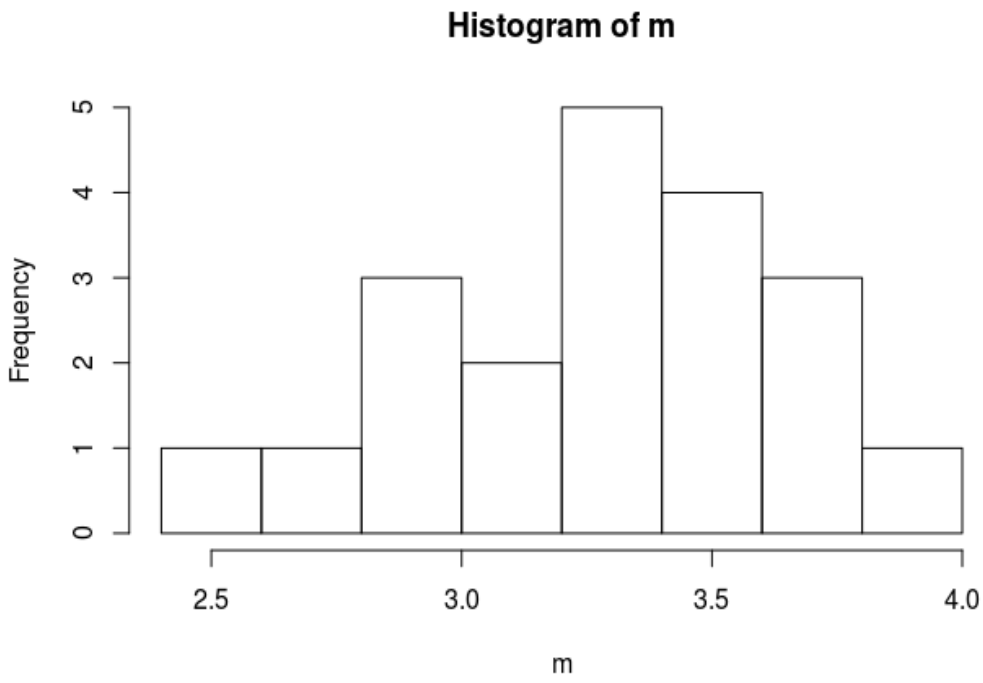

شکل ۱۱: هیستوگرام ۲۰ نمونه به سایز۵۰ از توزیع نمایی

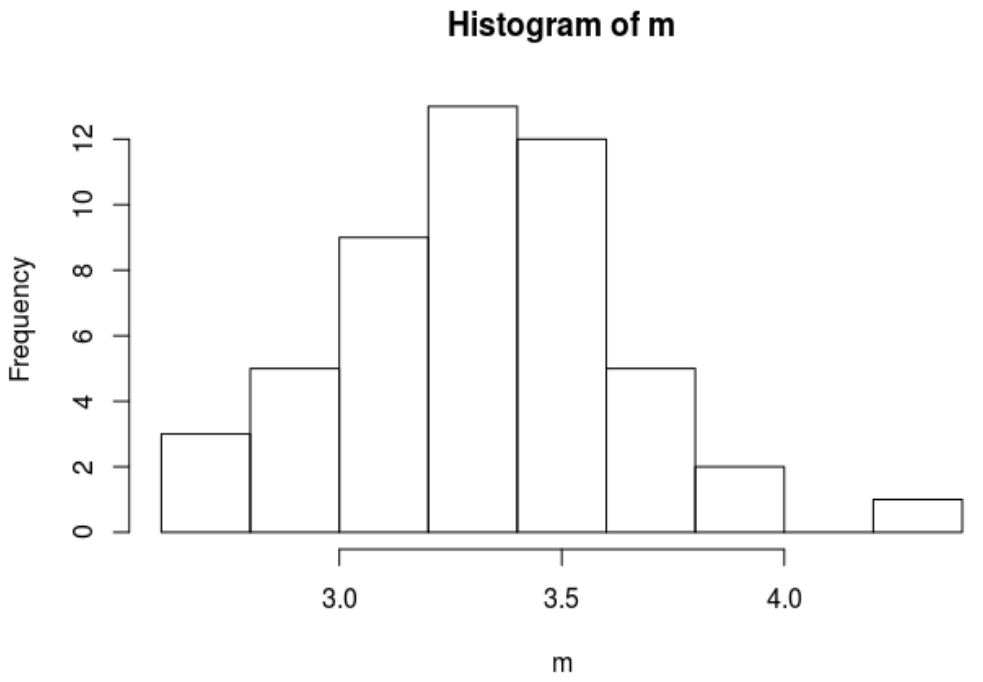

شکل ۱۲: هیستوگرام ۵۰ نمونه به سایز ۵۰ از توزیع نمایی

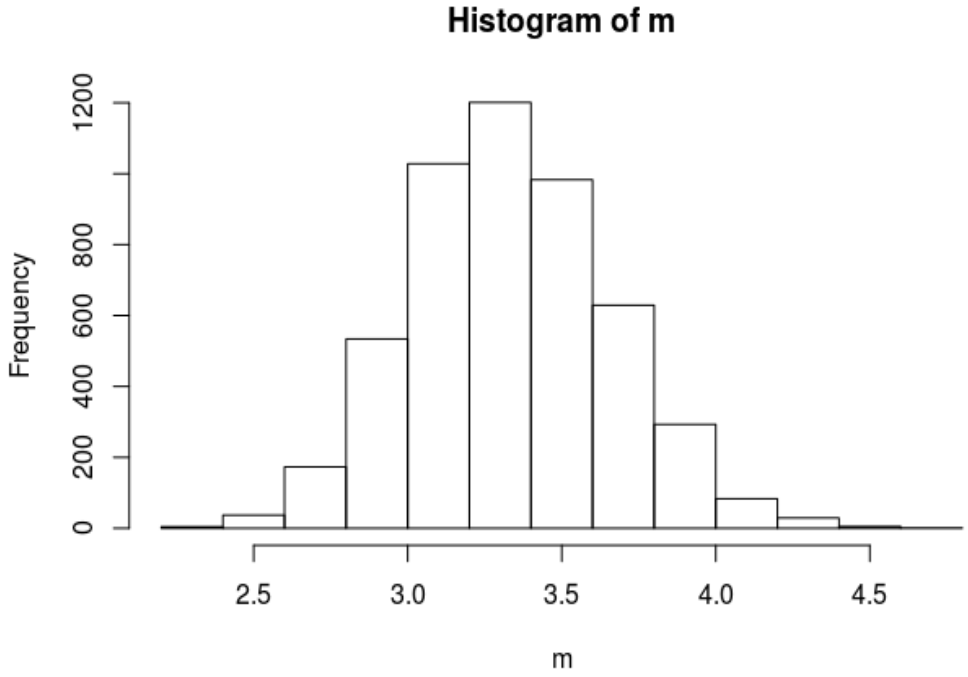

شکل ۱۳: هیستوگرام ۵۰۰ نمونه به سایز ۵۰ از توزیع نمایی

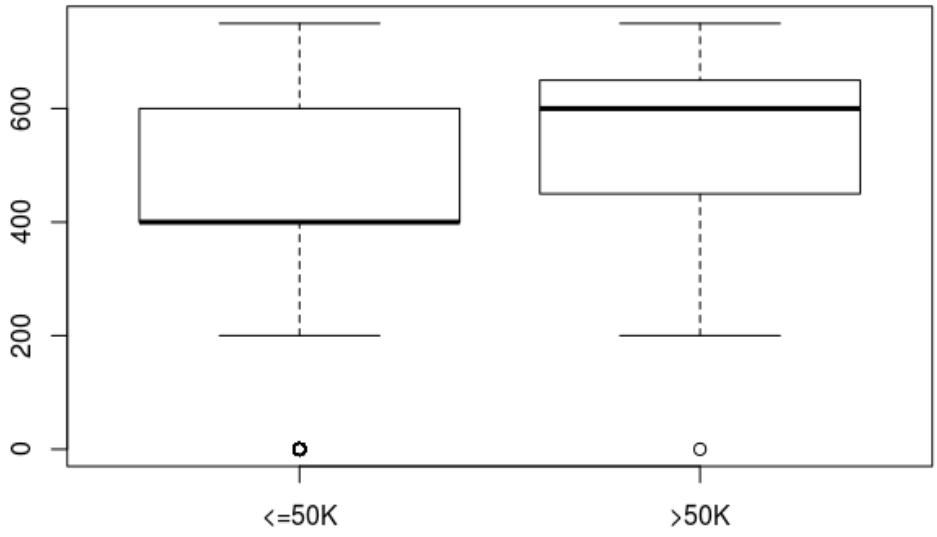

شکل ۱۴: نمودار مقدار تحصیلات برحسب درآمد